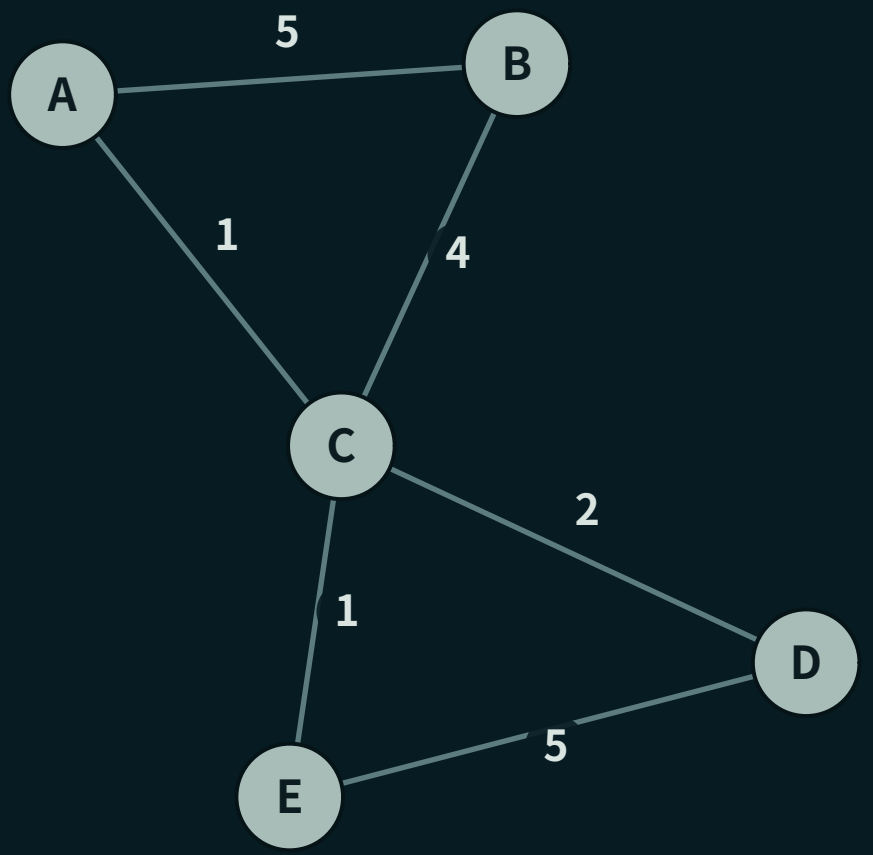
合并，再合并

Greedy pair merge · 凝聚式聚类

Learning Clustering · 原作者 thy031（Issue #2）

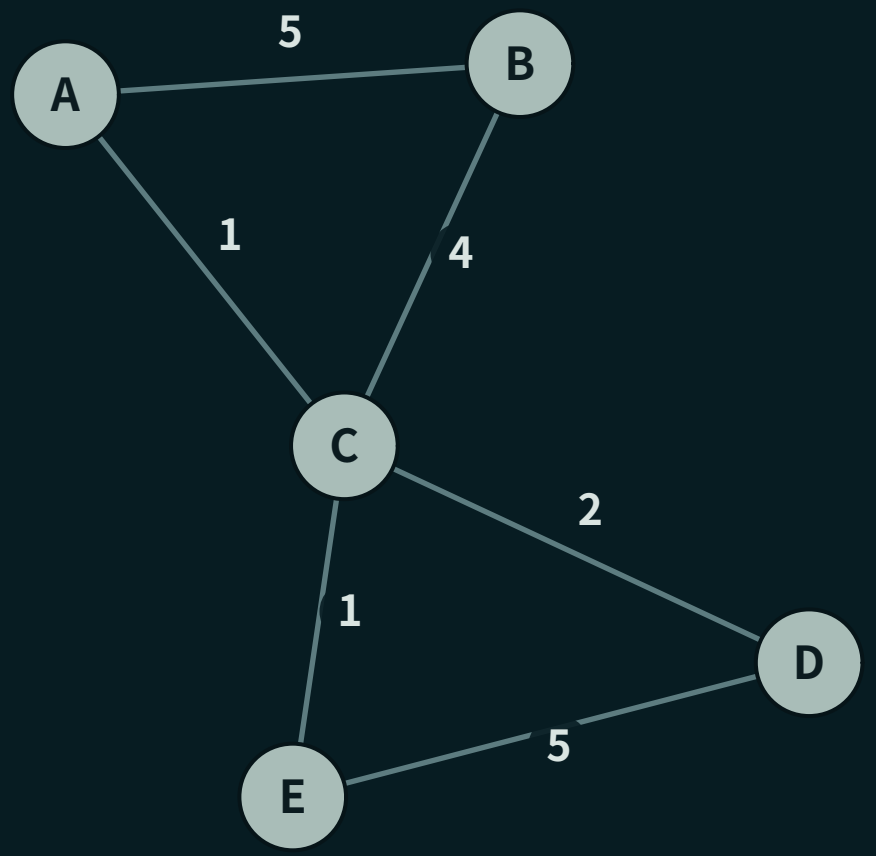
问题定义

- 输入：带权无向图、目标簇数 K、可选容量 C
- 每一步：合并亲和度 > 0 且合法的“最亲近”一对
- 停止：簇数达到 K，或没有合法的正亲和度对
- 输出：簇、cut、是否达到 K、停止原因、每步记录
- 绝不为凑 K 强行合并，也不撤销已做的合并



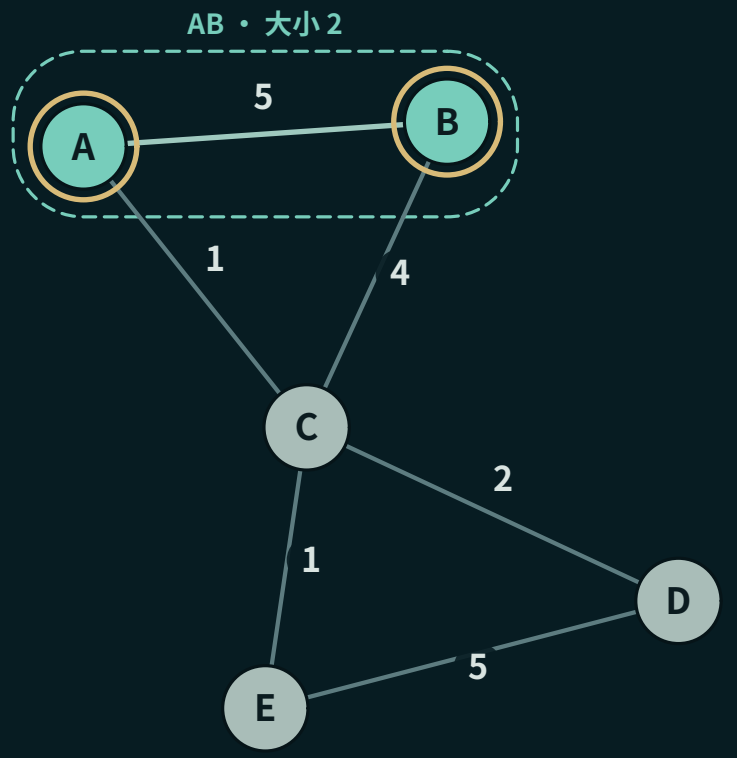
单点簇、K 与簇间亲和度

- 单点簇：开始时每个节点自成一簇，cut = 全部边权 18
- 簇间亲和度：两个簇之间所有边权之和
- 收缩：两簇之间的边变成内部边，平行边相加
- 每次合并，cut 恰好下降这一次的亲和度



选择键与平票规则

- 选择键 (−亲和度, 簇 A 成员, 簇 B 成员)，逐字段比较取最小
- 第一字段取负：亲和度大的排前
- 第一步 A–B 与 D–E 都是 5：比较 A 与 D，选 A–B
- cut 18 → 13

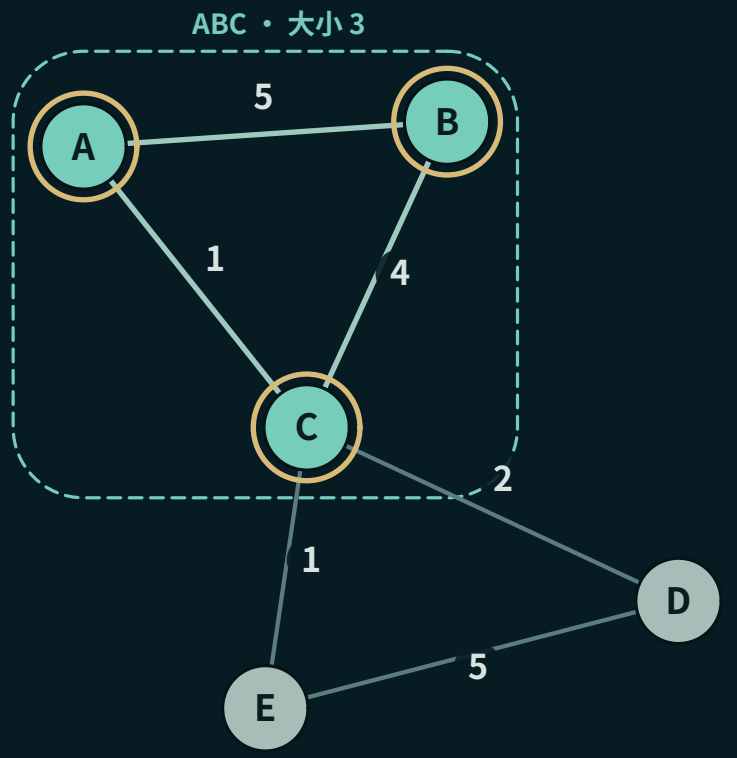


候选	亲和度
A–B	5
D–E	5
B–C	4
C–D	2

cut 18 → 13

收缩：平行边相加

- A、B 收缩为超节点 AB（原作者 thy031 的核心示意）
- AB–C = A–C 1 + B–C 4 = 5
- 与 D–E 再次并列 5：[A, B] < [D]，选 AB–C
- cut 13 → 8



候选	亲和度
AB–C	5
D–E	5
C–D	2
C–E	1

cut 13 → 8

完整轨迹：18 → 13 → 8 → 3

- 第 3 步：D–E = 5，cut 8 → 3，簇数到 2，停止
- 结果 ABC | DE
- 剩余 cut：C–D 2 + C–E 1 = 3
- K = 3 时在第 2 步后停：ABC | D | E，cut 8

步	合并	亲和度	cut
0	—	—	18
1	A + B	5	13
2	AB + C	5	8
3	D + E	5	3

原网页的比较器错误（已修正）

- 原 JS：if (!best || cand < best)，cand 是数组
- JavaScript 比较数组前先转成字符串
- "-1,A,C" < "-5,A,B"：亲和度 1 被当成更好
- 四个配置 9/16/12/16，正确为 3/8/8/3
- 修正：逐字段比较；回归测试 10 vs 2、2.5 vs 2

[−5, "A", "B"] → "-5,A,B"

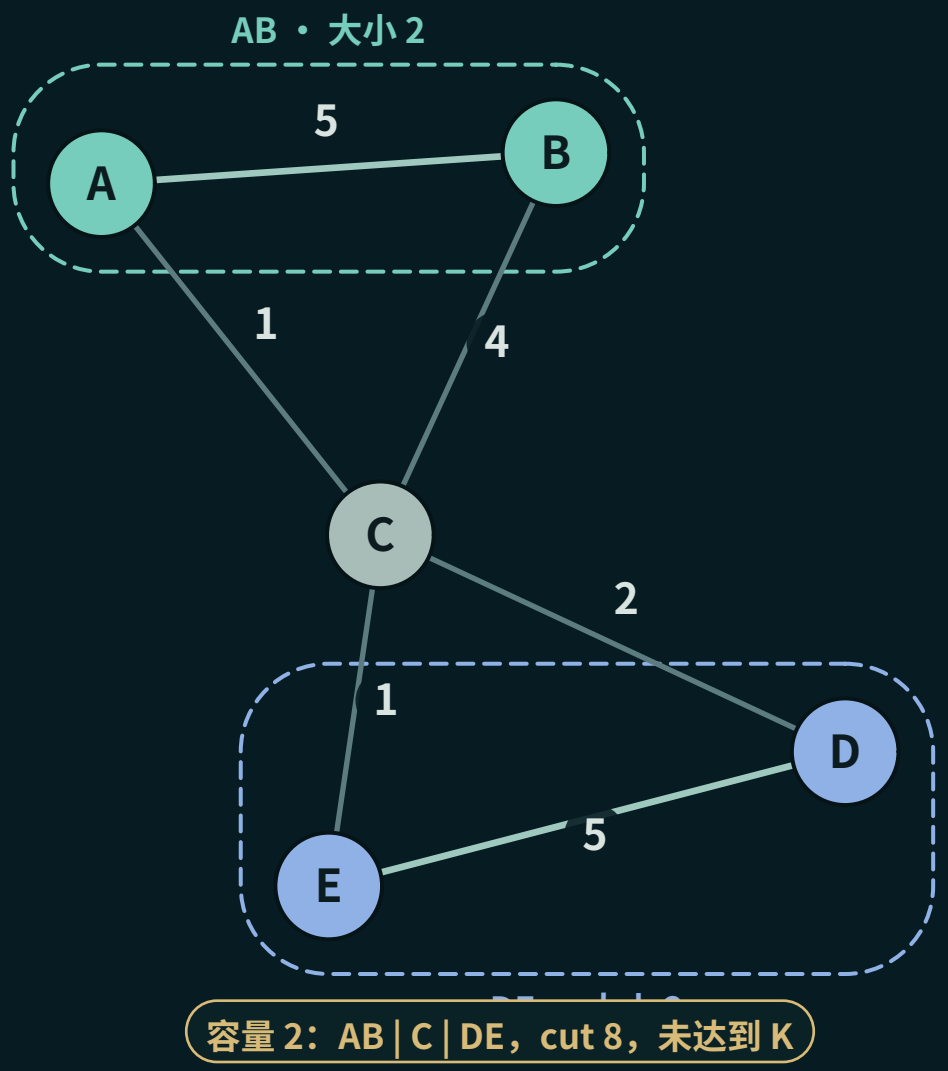
[−1, "A", "C"] → "-1,A,C"

字符 1 < 5：亲和度 1 的 A–C 被当成更好

配置	原网页	正确
K=2	9	3
K=3	16	8
K=2 容量2	12	8
K=2 容量3	16	3

容量预览与停止状态

- 容量 C = 2：AB + C 的大小 3 > 2，被阻止
- 转选 D–E；之后 AB+C、C+DE 都超容量
- 停止：AB | C | DE，3 簇，cut 8
- 合法（每簇 ⩽ 2）但未达到 K = 2
- 容量 3：轨迹与不限容量相同



伪代码逐行

- 第 2 行：簇数达到 K 就停
- 第 3–4 行：列出正亲和度候选，过滤超容量
- 第 5 行：没有合法候选就停，如实报告
- 第 6 行：逐字段比较选择键
- 第 7 行：收缩，cut 下降该亲和度

```
1  clusters ← 每个节点一个单点簇
2  while 簇数 > K:
3      cands ← 亲和度 > 0 的簇对
4      legal ← 合并后大小 ⩽ C 的候选
5      if legal 为空: 停止（如实报告）
6      选 (−亲和度, P, Q) 最小的一对
7      收缩 P ∪ Q：cut 下降该亲和度
8  返回 簇、cut、是否达到 K、停止原因
```

常见错误

- 把候选数组当字符串比较：第一步错选 A–C
- 为了凑 K 强行做超容量合并
- 收缩后忘记平行边相加：AB–C 误算成 4
- 看到 cut 3 就认为贪心总是最优

局限与工程含义

- 不回撤：早期合并错了，后面无法纠正（反例见 Module 04）
- 依赖评分与平票规则
- 朴素实现每步检查所有簇对；实际工具用优先队列与局部更新
- 芯片设计中常用于把大量单元粗化成较少的簇，并限制簇面积

小结

每次合并最亲近的合法一对；数值优先，平票看名字。

cut 每步下降该次亲和度；达到 K 或无合法对就停，如实报告。

下一模块：容量成为主角——装不下，还是走错了路？